



Hochschule für angewandte Wissenschaften Coburg  
Fakultät Elektrotechnik und Informatik

Studiengang: Bachelor Informatik

# Einfluss von Unsicherheits-Visualisierungen auf Entscheidungsfindungen an Finanzmärkten

Keck, Paul

Abgabe der Arbeit: 10.06.2024

Betreut durch:

Prof. Helbig, Hochschule Coburg

# Inhaltsverzeichnis

<b>Abbildungsverzeichnis</b>	<b>3</b>
<b>1 Einführung</b>	<b>4</b>
1.1 Die Bedeutung von Unsicherheit in Finanzmärkten . . . . .	5
1.2 Ziele der Arbeit . . . . .	5
<b>2 Theorien zur Entscheidungsfindung unter Unsicherheit</b>	<b>6</b>
2.1 Erwartungsnutzentheorie . . . . .	6
2.2 Dual-Process-Theorie . . . . .	6
2.3 Vergleich der Theorien . . . . .	7
<b>3 Unsicherheitsvisualisierung zur Entscheidungsstützung</b>	<b>7</b>
3.1 Fallstudie Fantasy Football . . . . .	7
3.2 Quantile Dotplots . . . . .	8
<b>4 Monte Carlo Simulationen zur Unterstützung von Investmententscheidungen</b>	<b>9</b>
4.1 Grundprinzipien der Monte Carlo Methode . . . . .	10
4.2 Monte Carlo in der Risikonalalyse . . . . .	10
<b>5 Übertragung von Erkenntnissen auf die Finanzwelt</b>	<b>11</b>
5.1 Eigene Monte Carlo Simulation mit Quantile Dotplot Darstellung . . . . .	12
5.2 Diskussion . . . . .	12
<b>6 Fazit und Ausblick</b>	<b>13</b>
6.1 Zusammenfassung der wichtigsten Erkenntnisse . . . . .	13
6.2 Vorschläge für künftige Forschung . . . . .	13
<b>Literaturverzeichnis</b>	<b>14</b>
<b>Ehrenwörtliche Erklärung</b>	<b>16</b>

## Abbildungsverzeichnis

Abb. 1:	Monte Carlo Simulation der AAPL-Aktienkurse . . . . .	12
Abb. 2:	Quantile Dotplot der simulierten AAPL-Aktienkurse . . . . .	12
Abb. 3:	Gegenüberstellung herkömmliche Visualisierung vs. Quantile Dotplot . . . .	12

# 1 Einführung

Eine fundamentale Unterscheidung in den Wirtschaftswissenschaften, eingeführt von Frank H. Knight, ist die zwischen Risiko und Unsicherheit. Knight definiert Risiko als quantifizierbare Unsicherheit, also Situationen, in denen jedem möglichen Ausgang eine Wahrscheinlichkeit zugeordnet werden kann. Klassische Beispiele hierfür sind Versicherungen oder Glücksspiel im Casino, bei denen ein Gewinn zwar unsicher ist, man aber weiß, dass die Kugel mit einer Wahrscheinlichkeit von  $p = 1/37$  auf einem spezifischen Feld landen wird.

Im Gegensatz dazu bezieht sich die von Knight definierte Unsicherheit, die er als "echte Unsicherheit" bezeichnet, auf Situationen, in denen keine definitive Wahrscheinlichkeit für die möglichen Ausgänge zugeordnet werden kann. Dies ist der Fall, wenn keine historischen Daten vorliegen, anhand derer Wahrscheinlichkeiten abgeleitet werden könnten [Kni21]. Ein reales Beispiel wäre der Marktstart eines neuartigen, innovativen Produktes ohne vergleichbare Wettbewerber, wie zum Beispiel der Streaming-Dienst von Netflix.

In unserer heutigen, von Innovation und Schnelligkeit geprägten Welt ist das Verständnis von Risiko und Unsicherheit besonders wichtig. Unternehmer müssen ständig Entscheidungen treffen, die weitreichende Konsequenzen haben können. Die Fähigkeit, Unsicherheiten richtig einzuschätzen, darzustellen und eventuell zu nutzen, kann den Unterschied zwischen Erfolg und Misserfolg ausmachen.

Die Darstellung von Unsicherheit in der Datenvisualisierung hat viele ähnliche, aber auch zahlreiche unterschiedliche Definitionen im Vergleich zu Knight. Haber und McNabb [HM90] beschreiben eine Visualisierungs-Pipeline, die in vielen Arbeiten zur Unsicherheitsvisualisierung aufgegriffen wird, unter anderem in einem Standardwerk von Pang et al. [PWL97]. Diese Pipeline reicht von der Datenbeschaffung bis zur endgültigen Visualisierung und berücksichtigt Unsicherheiten in jedem Schritt:

1. **Datenbeschaffung:** In dieser Phase ist Unsicherheit immer vorhanden, sei es durch Messfehler oder -ungenauigkeiten, die Beschaffung der Daten durch statistische Modelle oder unvollständige Daten. Eine Messung kann nie zu 100% genau sein.
2. **Datenvorverarbeitung:** Die beschafften Daten müssen in einem nachfolgenden Schritt aufbereitet werden, in dem durch Interpolation von fehlenden Daten, ungenaue Transformationen oder Annahmen weitere Unsicherheiten einfließen können.
3. **Datenverarbeitung und -analyse:** Diese Daten werden zur Visualisierung auf ein oder mehrere geometrische Objekte gemappt. Dies stellt durch die verwendeten Algorithmen und Modelle eine neue Quelle von Unsicherheit dar.

4. **Visualisierung:** Schließlich werden die Daten visualisiert. Hier können Unsicherheiten durch die Wahl der Visualisierungstechniken und Darstellungsparameter wie Farbskalen und Fehlerbalken beeinflusst werden.

Man erkennt viele verschiedene Arten von Unsicherheit in dieser Pipeline, sei es durch Messfehler oder falsche Annahmen. In dieser Arbeit wird jedoch hauptsächlich auf Finanzprognosen eingegangen, weshalb es hier um die in der nächsten Sektion beschriebenen Arten von Unsicherheit geht.

### 1.1 Die Bedeutung von Unsicherheit in Finanzmärkten

Eine weitere Ansicht aus Knights Werk ist, dass ein Unternehmer nur wirtschaftlich erfolgreich sein kann, wenn er Unsicherheiten auf sich nimmt. Andernfalls hätten alle Wettbewerber die gleichen, korrekten Informationen, und kein Vorteil könnte erzielt werden. Wird diese aufzunehmende Unsicherheit aber im Entscheidungsprozess falsch oder unzureichend dargestellt, kann dies fatale Folgen nach sich ziehen.

Man stelle sich beispielsweise die Prognose eines Aktienkurses anhand eines Monte-Carlo-Modells vor. Sollte ein Investor auf Basis dieser Prognose eine Entscheidung treffen, ist er einerseits mit der direkten quantitativen Unsicherheit der Vorhersage konfrontiert, also mit der Wahrscheinlichkeit, dass genau der gewählte Zweig der Simulation zutrifft. Andererseits gibt es die indirekte qualitative Unsicherheit: Hat der Ersteller korrekt historische Daten verwendet? [PKH21] Auf welcher Basis von Zufall wurde die Prognose erstellt – Volatilität oder fundierte ökonomische Kennzahlen des Unternehmens? Es gilt, diese Unsicherheiten so gut wie möglich darzustellen, um den Investor bei seiner Entscheidungsfindung zu unterstützen und keine Trugschlüsse zuzulassen.

### 1.2 Ziele der Arbeit

Deshalb wird in dieser Arbeit untersucht, wie sich die Visualisierung von Unsicherheiten und Risiken auf Entscheidungsträger auswirkt und wie Techniken angewandt werden können, um die Kommunikation von Informationen sicherer zu machen und zu verbessern. Dies geschieht im Rahmen der Finanzwelt.

Im folgenden Kapitel werden Grundlagen zur Entscheidungsfindung von Menschen und Techniken der Visualisierung von Unsicherheiten beleuchtet.

## 2 Theorien zur Entscheidungsfindung unter Unsicherheit

Es werden Theorien zur Entscheidungsfindung unter Unsicherheit näher beleuchtet, die laut Padilla et al. [SBC<sup>+</sup>23] berücksichtigt werden müssen, um Visualisierungstechniken auf Basis ihrer Rolle in Entscheidungsfindungen unter Unsicherheit bewerten zu können. Diese werden in Sektion 3 wieder aufgegriffen, um den Effekt unterschiedlicher Visualisierungsmethoden auf die Entscheidungsfindung zu erklären.

### 2.1 Erwartungsnutzentheorie

Die Erwartungsnutzentheorie (EUT) ist ein grundlegendes Modell in der Entscheidungstheorie, das beschreibt, wie rationale Akteure Entscheidungen unter Unsicherheit treffen sollten. Entwickelt von John von Neumann und Oskar Morgenstern, basiert die EUT auf der Annahme, dass Akteure bei der Wahl zwischen unsicheren Alternativen die Option bevorzugen, welche den höchsten erwarteten Nutzen bietet. Dieser erwartete Nutzen eines Ergebnisses wird dabei als das Produkt aus der Wahrscheinlichkeit des Ergebnisses und dem subjektiven Nutzen dieses Ergebnisses berechnet.

Die mathematische Darstellung der Erwartungsnutzentheorie geht wie folgt:

$$EU = \sum_{i=1}^n p_i \cdot u(x_i) \quad (2.1)$$

Dabei ist  $EU$  der erwartete Nutzen,  $p_i$  die Wahrscheinlichkeit des Ergebnisses  $x_i$  und  $u(x_i)$  der Nutzen des Ergebnisses  $x_i$ .

Die EUT geht davon aus, dass Akteure gleichbleibende Präferenzen haben und immer die Alternative mit dem höchsten erwarteten Nutzen wählen [NM44]. Diese Theorie hat viele Anwendungen in der Finanzwelt, beispielsweise bei der Analyse von Investitionen und Risiken.

### 2.2 Dual-Process-Theorie

Die Dual-Process-Theorie beschreibt, wie Menschen zwei verschiedene Arten von Denkprozessen nutzen, um Entscheidungen zu treffen: intuitives (Type 1) und analytisches (Type 2) Denken. Die Grundlagen für diese Theorie wurden von Psychologen wie Daniel Kahneman und Keith Stanovich über Jahre entwickelt und heben hervor, dass Menschen je nach Situation und Komplexität der Aufgabe zwischen diesen beiden Denkmodi wechseln [TK74].

- **Type 1 Prozesse:** Diese sind schnell, automatisch und erfordern wenig kognitive Anstrengung. Sie basieren auf Intuition, die oft aus Erfahrungen und erlernten Mustern

hervorkommen. Type 1 Prozesse sind nützlich in routinemäßigen und vertrauten Situationen, können jedoch zu systematischen Fehlern und Trugschlüssen führen.

- **Type 2 Prozesse:** Diese sind langsam, bewusst und erfordern einiges an kognitiver Anstrengung. Sie basieren auf logischem Denken und systematischer Analyse. Type 2 Prozesse kommen zum Einsatz, wenn komplexe und neue Situationen eine tiefgehende Bewertung erfordern.

Die Dual-Process-Theorie erklärt, warum Menschen in vielen Situationen intuitive Entscheidungen treffen, die schnell und effizient sind, aber eben auch öfter zu suboptimalen Ergebnissen führen. Sie betont auch, wie wichtig es ist, analytisches Denken zu fördern, insbesondere bei komplexen und wichtigen Entscheidungen, bei denen Fehler schwere Konsequenzen haben können.

## 2.3 Vergleich der Theorien

Die Erwartungsnutzentheorie und die Dual-Process-Theorie bieten unterschiedliche Perspektiven auf die Entscheidungsfindung unter Unsicherheit. Während die EUT ein Modell ist, das beschreibt, wie Entscheidungen getroffen werden sollten, bietet die Dual-Process-Theorie ein beschreibendes Modell, das erklärt, wie Entscheidungen tatsächlich getroffen werden. Die EUT geht von rationalen und gleichbleibenden Präferenzen aus, wohingegen die Dual-Process-Theorie die Rolle von Intuition betont, die zu systematischen Fehlern führen kann.

## 3 Unsicherheitsvisualisierung zur Entscheidungsstützung

Um die Bedeutung der Visualisierung von Unsicherheiten auf die Entscheidungsfindung besser zu verstehen, wird eine Fallstudie beleuchtet, die genau das untersucht hat. Anschließend werden die beiden daraus resultierenden, erfolgversprechendsten Visualisierungsmethoden näher betrachtet.

### 3.1 Fallstudie Fantasy Football

In der Fallstudie von Kale et al. [KKH21] wurde untersucht, wie verschiedene Unsicherheitsvisualisierungen die Entscheidungsfindung beeinflussen können. Die Teilnehmer der Studie nahmen an einem fiktiven Fantasy-Football-Spiel teil, dessen Ziel es war, einen 3,7 Mio. Dollar Wettbewerb zu gewinnen. In diesem mussten Entscheidungen darüber getroffen werden, ob sie für Kosten von 1 Mio. Dollar einen neuen Spieler zu ihrem Team hinzufügen sollten oder nicht. Die Visualisierungen zeigten, wie viele Punkte sie ohne Hinzufügen des Spielers beziehungsweise nach Hinzufügen erzielen würden.

Die Studie testete verschiedene Visualisierungsdesigns, darunter 95%-Intervallbereiche, hypothetische Ergebnisszenarien, Dichteplots und Quantile Dotplots, jede mit und ohne Darstellung der Mittelwerte. Es wurde untersucht, anhand welcher Visualisierung am besten abgeschätzt wurde, ob es sinnvoll wäre, den neuen Spieler hinzuzufügen, um den höchsten monetären Gewinn (3,7 Mio. Dollar falls Gewinn ohne, 2,7 Mio. Dollar falls Gewinn mit Hinzufügen eines neuen Spielers) zu erzielen.

Die Ergebnisse der Studie zeigten, dass Quantile Dotplots die genaueste Abschätzung der Auswirkung und die besten Entscheidungen förderten, insbesondere bei geringer Varianz. Diese Methode half den Nutzern, die Unsicherheit intuitiver zu verstehen und bessere Entscheidungen zu treffen, indem sie Wahrscheinlichkeiten und Verteilungen klar darstellte.

Padilla et al. nutzten diese Fallstudie, um zu zeigen, wie man die EUT anwenden kann, um Visualisierungsmethoden nach ihrer Fähigkeit zu bewerten, rationale Entscheidungen zu unterstützen. Die Teilnehmer wurden vor eine binäre Entscheidung (Spieler kaufen/nicht kaufen) gestellt, bei der sie bewerten mussten, ob dieser ihren erwarteten Nutzen maximiert oder nicht [SBC<sup>+</sup>23].

Weitergehend wird genauer auf die hervorgekommene Methode der Quantile Dotplots eingegangen.

## 3.2 Quantile Dotplots

Quantile Dotplots sind eine Visualisierungstechnik, die Unsicherheit durch diskrete Punkte darstellt, die bestimmte Quantile einer Verteilung repräsentieren. Diese Methode hilft den Nutzern, Wahrscheinlichkeiten und Verteilungen auf intuitive Weise zu verstehen, indem sie Hinweise liefert, die leicht gezählt und interpretiert werden können.

Kay et al. [KKHM16] haben diese Visualisierungstechnik in ihrer Studie begründet und gezeigt, dass Quantile Dotplots die Genauigkeit von Entscheidungsfindungen verbessern können. Die Studie zielte darauf ab, Unsicherheiten bei der Vorhersage von Ankunftszeiten von Bussen auf mobilen Geräten besser darzustellen.

Dazu entwickelten Kay et al. mehrere Visualisierungsdesigns, darunter Quantile Dotplots, und führten eine umfassende Analyse durch, die folgende Schritte umfasste:

- **Literaturüberblick und Nutzerumfragen:** Sie führten eine Literaturrecherche und eine Umfrage unter 172 Nutzern einer beliebten Echtzeit-Bus-Anwendung durch (man stelle sich DB-Navigator vor), um die Bedürfnisse und Herausforderungen der Nutzer bei der Darstellung von Unsicherheit zu verstehen.
- **Iterativer Designprozess:** Basierend auf den gesammelten Informationen entwickelten sie verschiedene Visualisierungsdesigns, die die Unsicherheit bei der Busankunft auf mobilen



Bildschirmen darstellen sollten. Sie führten iterative Tests und Verbesserungen dieser Designs durch.

- **Experimentelle Bewertung:** In einem kontrollierten Experiment verglichen sie die Effektivität verschiedener Visualisierungen. Die Ergebnisse zeigten, dass Quantile Dotplots die Varianz der Schätzungen um etwa das 1,15-fache im Vergleich zu Dichteplots reduzierten und den Nutzern halfen, präzisere und selbstbewusstere Schätzungen abzugeben.

Die Dual-Process-Theorie, die besagt, dass Menschen sowohl intuitive (Type 1) als auch analytische (Type 2) Denkprozesse nutzen, findet in der Nutzung von Quantile Dotplots eine sinnvolle Anwendung:

- **Type 1 Prozesse (intuitives Denken):** Die diskreten Punkte der Quantile Dotplots ermöglichen eine schnelle und einfache Erfassung der Unsicherheiten. Nutzer können die Verteilung und die Wahrscheinlichkeiten abschätzen, ohne tiefes analytisches Denken, was besonders in alltäglichen und routinemäßigen Entscheidungen nützlich ist.
- **Type 2 Prozesse (analytisches Denken):** Für Nutzer, die eine tiefere und genauere Analyse durchführen möchten, bieten Quantile Dotplots detaillierte Informationen, die eine präzise Bewertung der Unsicherheiten ermöglichen. Durch das Zählen der Punkte können Nutzer genaue Wahrscheinlichkeiten und Intervalle berechnen, was zu besser fundierten Entscheidungen führt.

Diese Technik schneidet also nicht nur in den üblichen Bewertungsmaßen von Visualisierungsmethoden, wie der Genauigkeit und Geschwindigkeit der Informationsvermittlung, gut ab, sondern verbessert nach obigen Beispielen und Fernandes et al. [FWM<sup>+</sup>18] auch die Fähigkeit, rationale Entscheidungen zu treffen. Im Folgenden wird versucht, dies auf eine der beliebtesten Prognoseverfahren bei Investments anzuwenden.

## 4 Monte Carlo Simulationen zur Unterstützung von Investmententscheidungen

Die Monte Carlo Methode ist eine statistische Technik, die zur Modellierung und Analyse von Situationen/Systemen verwendet wird, bei denen Unsicherheit und Zufälligkeit eine Rolle spielen. Sie wurde während des Zweiten Weltkriegs von Stanislaw Ulam und John von Neumann entwickelt und nach dem berühmten Casino von Monte Carlo benannt, eben weil die Methode auf Zufallsprozessen basiert, ähnlich wie Glücksspiele [WB14].

### 4.1 Grundprinzipien der Monte Carlo Methode

Die Monte Carlo Methode besteht darin, ein Modell viele Male zu simulieren, wobei jede Simulation zufällige Eingabewerte verwendet, die aus einer bestimmten Wahrscheinlichkeitsverteilung gezogen werden. Das ermöglicht es, die Verteilung der möglichen Ergebnisse des Modells zu verstehen und darzustellen, sowie wichtige statistische Größen wie den Mittelwert, die Standardabweichung und Konfidenzintervalle zu berechnen.

Die zwei Hauptprinzipien der Monte Carlo Methode sind:

- **Ergodizität:** Dies bedeutet, dass das System von jedem möglichen Zustand aus jeden anderen Zustand erreichen kann, wenn genügend Zeit zur Verfügung steht. Dies ist wichtig, um sicherzustellen, dass alle möglichen Ergebnisse im Modell berücksichtigt werden.
- **Detaillierte Balance:** Diese Regel stellt sicher, dass das System im Gleichgewicht bleibt, indem die Übergangswahrscheinlichkeiten zwischen Zuständen gleich gewählt werden. Also die Wahrscheinlichkeit, von einem Zustand A zu einem Zustand B zu wechseln, ist gleich der Wahrscheinlichkeit von B nach A zu wechseln, multipliziert mit dem Verhältnis ihrer Wahrscheinlichkeiten [WB14].

Der häufigste eingesetzte Algorithmus in der Monte Carlo Methode ist der Metropolis-Algorithmus. Dieser funktioniert wie folgt:

- Ein zufälliger Zustand des Systems wird ausgewählt.
- Eine kleine zufällige Änderung dieses Zustands wird vorgeschlagen.
- Die Änderung wird akzeptiert, wenn sie die gewünschte Eigenschaft (z.B. niedrigere Energie) verbessert, oder mit einer bestimmten Wahrscheinlichkeit, wenn sie diese Eigenschaft verschlechtert [WB14].

Die Monte Carlo Methode wird häufig in der Risikoanalyse von Investitionen verwendet. Sie hilft dabei, die Unsicherheit und das Risiko, die mit einem Projekt verbunden sind, zu quantifizieren, indem sie die Verteilung aller möglichen Ergebnisse des Projekts simuliert. Dies ermöglicht es Entscheidungsträgern, fundierte Entscheidungen zu treffen und geeignete Maßnahmen zur Risikominimierung zu ergreifen.

### 4.2 Monte Carlo in der Risikoanalyse

Platon und Constantinescu haben die Monte Carlo Methode verwendet, um die Risiken von Umweltprojekten in Rumänien zu analysieren. Sie untersuchten 23 Abfallwirtschaftsprojekte

und 40 Wasser- und Abwasserprojekte, wonach ein zufällig ausgewähltes genauer untersucht wurde. Dieses hatte geplante Projektkosten von 51,76 Mio.€ und eine geplante Projektdauer von 45 Monaten. Die Monte Carlo Simulation wurde verwendet, um die Risiken im Zusammenhang mit der Überschreitung der Projektkosten und der Projektdauer zu bewerten [PC14].

Ein Projektmanager müsste beispielsweise bewerten können, ob die angesetzten Kosten wirklich ausreichend sind, um das Projekt umzusetzen. Setzt er sie zu hoch an, wird die Wahrscheinlichkeit steigen, dass er den Rahmen nicht sprengen wird, jedoch wird es das Projekt natürlich unattraktiver machen beziehungsweise gar nicht genehmigt. Zieht man die EUT aus Abschnitt 2.1 heran, hat er einen hohen erwarteten Nutzen, wenn die Projektkostenestimierung niedrig ausfällt (dementsprechend die Wahrscheinlichkeit  $p$  für das Einhalten des Projektrahmens sinkt) und das Projekt gelingt. Es gilt also, die Entscheidung zu treffen, wie hoch das Risiko der Kostenüberschreitung sein kann, um den besten erwarteten Nutzen zu ziehen.

Der Prozess umfasste folgende Schritte:

- Zuerst wurden die Projektkosten in fünf unterschiedliche Kategorien aufgeteilt, wie Arbeitskosten, Kosten der Baufläche etc., woraufhin ein Intervall für jede dieser geschätzt wurde, in welchem sich die wahren Kosten befinden sollten.
- Es wurde mittels Zufallszahlen für jede dieser Kategorien eine Stichprobe gezogen und die Projektkosten für diesen Simulationsschritt aufaddiert. Dieser Schritt wurde tausendmal wiederholt, wodurch ein Durchschnittswert von 50,75 Mio.€ ermittelt wurde.

Demzufolge wurde die Wahrscheinlichkeit berechnet, dass die tatsächlichen Kosten die geplanten übersteigen werden und mit 32.74% angegeben. Dies ist eher unwahrscheinlich, bringt aber trotzdem eine gewisse Unsicherheit in der Projektplanung auf.

Das Paper von Platon et al. zeigt auf, wie Monte Carlo zur Untersuchung von Investitionen, hier näher Projekten, auf Unsicherheiten und Risiken genutzt werden kann. Diese Angaben wären als Visualisierung jedoch aussagekräftiger und könnten noch mehr Schlüsse aufbringen.

## 5 Übertragung von Erkenntnissen auf die Finanzwelt

Um die vorhergehenden Kenntnisse auf die Finanzwelt zu übertragen, wird eine Monte-Carlo-Simulation auf Aktienpreise durchgeführt, um mögliche Kursbewegungen zu simulieren. Diese werden anschließend als Quantile Dotplot visualisiert.

### 5.1 Eigene Monte Carlo Simulation mit Quantile Dotplot Darstellung

Für die Monte Carlo Simulation wurde die Aktie von "Apple Inc." (AAPL) gewählt und historische Daten genutzt, um zukünftige Preisbewegungen zu simulieren.

Es wurden folgende Schritte durchgeführt, die im Grunde auch wieder die eingangs erwähnte Visualisierungs-Pipeline aufgreifen:

1. **Datenbeschaffung:** Die historischen Preisdaten der Aktie wurden heruntergeladen.
2. **Berechnung der logarithmischen Renditen:** Berechnung der täglichen Preisänderungen in logarithmischer Form durch
$$R_t = \ln \left( \frac{P_t}{P_{t-1}} \right)$$
wobei  $R_t$  die logarithmische Rendite,  $P_t$  den Preis am Tag  $t$  und  $P_{t-1}$  den Preis am Tag davor darstellt.
3. **Statistische Parameter:** Berechnung des Mittelwerts und der Standardabweichung der logarithmischen Renditen.
4. **Monte Carlo Simulation:** Simulation von 1000 möglichen Kursverläufen über die nächsten 252 Tage (ein Börsenjahr, Simulationsstart 31.05.2024).
5. **Quantile Dotplot:** Visualisierung der Ergebnisse in einem Quantile Dotplot.

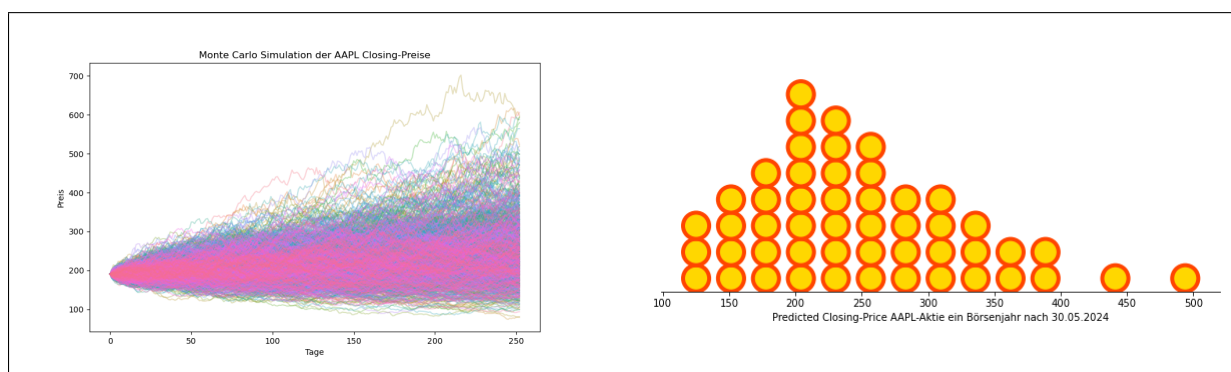


Abb. 3: Gegenüberstellung herkömmliche Visualisierung vs. Quantile Dotplot

### 5.2 Diskussion

Die Monte Carlo Simulation ermöglicht eine Analyse der zukünftigen Preisbewegungen der Aktie. Durch die Darstellung als Quantile Dotplot können wir die Unsicherheiten und Risiken,

die mit den zukünftigen Preisbewegungen verbunden sind, besser verstehen. Dies hilft Investoren dabei, bessere Entscheidungen im Bezug auf die Investition in diese Aktie zu treffen.

Vergleicht man in Abbildung 3 die Verläufe der einzelnen Simulationen im Vergleich zu der Darstellung der Verteilung in einem Quantile Dotplot, ist klar zu erkennen, aus welcher Darstellung man eher die Tendenzen der zukünftigen Kursverläufe erkennen kann. Während der Monte Carlo Plot die Unsicherheiten in den einzelnen simulierten Kursverläufen darstellt, bietet der Quantile Dotplot eine kompaktere und klarere Darstellung der Verteilung der Endpreise. Man beachte, dass dies zum Beispiel als erste schnelle Analyse der Aktie genutzt wird, wobei ein Investor etliche dieser am Tag sehen würde. Der Quantile Dotplot bringt einen intuitiveren Überblick und wie bereits ausgearbeitet definitive Vorteile für beide Denkprozesse nach Sektion 2.2.

## 6 Fazit und Ausblick

### 6.1 Zusammenfassung der wichtigsten Erkenntnisse

In dieser Arbeit wurde untersucht, wie sich die Visualisierung von Unsicherheiten und Risiken auf die Entscheidungsfindung auswirkt. Es wurden verschiedene Theorien zur Entscheidungsfindung unter Unsicherheit betrachtet, darunter die Erwartungsnutzentheorie und die Dual-Process-Theorie. Zudem wurde die Bedeutung der Visualisierung von Unsicherheiten anhand einer Fallstudie im Bereich Fantasy Football untersucht. Es zeigte sich, dass Quantile Dotplots eine effektive Methode zur Darstellung von Unsicherheiten sind und die Entscheidungsfindung verbessern können.

Die Anwendung dieser Erkenntnisse auf die Finanzwelt wurde durch eine Monte Carlo Simulation für eine Aktienprognose demonstriert. Die Visualisierung der Ergebnisse mittels Quantile Dotplots zeigte die Verteilung der möglichen zukünftigen Preise und half, die Unsicherheiten zu quantifizieren.

### 6.2 Vorschläge für künftige Forschung

Da der Forschungsbereich der Unsicherheitsvisualisierung rege ist, aber in der Domäne der Finanzen wenig bis kaum darüber geforscht wird, trotz der vielen Prognosen und Entscheidungen, die dort gefällt werden, sind weitreichende Studien zur Wirkung bereits entwickelter Unsicherheitsvisualisierungen aus anderen Domänen in der Finanzwelt mehr als wünschenswert. Anders als in der Medizin geht es dort nicht darum, Entscheidungen zu stützen, die über Menschenleben entscheiden können, aber dennoch um Existenzen. Auch sollen Laien einfacher die Schwere ihrer Entscheidungen nachvollziehen können.

## Literaturverzeichnis

- [FWM<sup>+</sup>18] FERNANDES, Michael ; WALLS, Logan ; MUNSON, Sean ; HULLMAN, Jessica ; KAY, Matthew: Uncertainty Displays Using Quantile Dotplots or CDFs Improve Transit Decision-Making. (2018), 1–12. <http://dx.doi.org/10.1145/3173574.3173718>. – DOI 10.1145/3173574.3173718. ISBN 9781450356206
  
- [HM90] HABER, R. B. ; MCNABB, D. A.: Visualization Idioms: A Conceptual Model for Scientific Visualization Systems. (1990), S. 74–93
  
- [KKH21] KALE, Alex ; KAY, Matthew ; HULLMAN, Jessica: Visual Reasoning Strategies for Effect Size Judgments and Decisions. In: *IEEE Transactions on Visualization and Computer Graphics* 27 (2021), Nr. 2, S. 272–282. <http://dx.doi.org/10.1109/TVCG.2020.3030335>. – DOI 10.1109/TVCG.2020.3030335
  
- [KKHM16] KAY, Matthew ; KOLA, Tara ; HULLMAN, Jessica R. ; MUNSON, Sean A.: When (ish) is My Bus? User-centered Visualizations of Uncertainty in Everyday, Mobile Predictive Systems. (2016), 5092–5103. <http://dx.doi.org/10.1145/2858036.2858558>. – DOI 10.1145/2858036.2858558. ISBN 9781450333627
  
- [Kni21] KNIGHT, Frank H.: *Risk, Uncertainty, and Profit*. Boston and New York : Houghton Mifflin Company, 1921 <https://www.econlib.org/library/Knight/knRUP.html>
  
- [NM44] NEUMANN, John von ; MORGENSTERN, Oskar: *Theory of Games and Economic Behavior*. 1. Princeton, NJ : Princeton University Press, 1944. – ISBN 978–0–691–00362–3
  
- [PC14] PLATON, Victor ; CONSTANTINESCU, Andreea: Monte Carlo Method in Risk Analysis for Investment Projects. In: *Procedia Economics and Finance* 15 (2014), S. 393–400. [http://dx.doi.org/10.1016/S2212-5671\(14\)00463-8](http://dx.doi.org/10.1016/S2212-5671(14)00463-8). – DOI 10.1016/S2212–5671(14)00463–8
  
- [PKH21] PADILLA, Lace ; KAY, Matthew ; HULLMAN, Jessica: Uncertainty Visualization. (2021), 02, S. 1–18. <http://dx.doi.org/10.1002/9781118445112.stat08296>. – DOI 10.1002/9781118445112.stat08296. ISBN 9781118445112
  
- [PWL97] PANG, Alex T. ; WITTENBRINK, Craig M. ; LODHA, Suresh K.: Approaches to Uncertainty Visualization. In: *The Visual Computer* 13 (1997), November, Nr. 8, 370–390. <http://dx.doi.org/10.1007/s003710050111>. – DOI 10.1007/s003710050111. – ISSN 1432–2315

- [SBC<sup>+</sup>23] SZAFIR, Danielle A. (Hrsg.) ; BORGO, Rita (Hrsg.) ; CHEN, Min (Hrsg.) ; EDWARDS, Darren J. (Hrsg.) ; FISHER, Brian (Hrsg.) ; PADILLA, Lace (Hrsg.): *Visualization Psychology*. 1. Cham, Switzerland : Springer Cham, 2023. <http://dx.doi.org/10.1007/978-3-031-34738-2>. <http://dx.doi.org/10.1007/978-3-031-34738-2>. – ISBN 978–3–031–34737–5. – Published: 06 November 2023, Softcover due: 08 December 2023, Number of Pages: XIX, 392, Number of Illustrations: 1 b/w illustrations
- [TK74] TVERSKY, Amos ; KAHNEMAN, Daniel: Judgment under Uncertainty: Heuristics and Biases. In: *Science* 185 (1974), Nr. 4157, 1124-1131. <http://dx.doi.org/10.1126/science.185.4157.1124>. – DOI 10.1126/science.185.4157.1124
- [WB14] WALTER, J.-C. ; BARKEMA, G. T.: An introduction to Monte Carlo methods. In: *Physica A* (2014). <https://arxiv.org/abs/1404.0209>

**Persönliche Angaben / Personal details**

Keck, Paul

Familienname, Vorname / Surnames, given names

06.05.2002

Geburtsdatum / Date of birth

Bachelor Informatik

Studiengang / Course of study

00767721

Matrikelnummer / Student registration number

**Eigenständigkeitserklärung*****Declaration***

Hiermit versichere ich, dass ich diese Arbeit selbständig verfasst und noch nicht anderweitig für Prüfungszwecke vorgelegt habe. Ich habe keine anderen als die angegebenen Quellen oder Hilfsmittel benutzt. Die Arbeit wurde weder in Gänze noch in Teilen von einer Künstlichen Intelligenz (KI) erstellt, es sei denn, die zur Erstellung genutzte KI wurde von der zuständigen Prüfungskommission oder der bzw. dem zuständigen Prüfenden ausdrücklich zugelassen. Wörtliche oder sinngemäße Zitate habe ich als solche gekennzeichnet.

Es ist mir bekannt, dass im Rahmen der Beurteilung meiner Arbeit Plagiatserkennungssoftware zum Einsatz kommen kann.

Es ist mir bewusst, dass Verstöße gegen Prüfungsvorschriften zur Bewertung meiner Arbeit mit „nicht ausreichend“ und in schweren Fällen auch zum Verlust sämtlicher Wiederholungsversuche führen können.

*I hereby certify that I have written this thesis independently and have not submitted it elsewhere for examination purposes. I have not used any sources or aids other than those indicated. The work has not been created in whole or in part by an artificial intelligence (AI), unless the AI used to create the work has been expressly approved by the responsible examination board or examiner. I have marked verbatim quotations or quotations in the spirit of the text as such.*

*I am aware that plagiarism detection software may be used in the assessment of my work.*

*I am aware that violations of examination regulations can lead to my work being graded as "unsatisfactory" and, in serious cases, to the loss of all repeat attempts.*

Unterschrift Studierende/Studierender / Signature student

<ORT>, den 10.06.2024

Ort, Datum / Place, date